





ПРОДАМ ГАРАЖ

х а к а т о н


СОСТАВ ГРУППЫ


- 1 Халилов Чингиз Первиз оглы
- 2 Дубнев Сергей Борисович
- 3 Водовозова Виктория Владиленовна
- 4 Сотсков Всеволод Викторович
- 5 Карелина Милана Аленовна







ЗНАЧИМОСТЬ ЗАДАЧИ





АРХИТЕКТУРА



PDF-документы

Поиск файлов document_NNN.pdf

Marker PdfConverter

Markdown + внутренние изображения

Нормализация имён изображений

Очистка битых ссылок

Сохранение .md и images/

Формирование submission.zip

ПОЧЕМУ MARKER?

PyMuPDF/pdfplumber

OCR-only

marker

Сохранение
структуры

структуру нужно
восстанавливать вручную

Может распознать текст, но
почти не понимает логическую
структуру документа

Хорошо восстанавливает
Markdown-структуру

Изображения

Изображения нужно
дополнительно искать

Обычно фокусируется на
тексте, а не на корректном
извлечении изображений

Возвращает изображения
отдельно

Таблицы

Работает нестабильно на
сложных таблицах

OCR видит таблицу как
картинку/текст, но структуру
строк и столбцов часто теряет

Может извлекать таблицы как
структурные элементы

Скорость
разработки

Нужно писать много
собственной логики

Нужно собирать OCR + layout +
Markdown-реконструкцию

Быстро даёт сильное решение


СЛАБЫЕ СТОРОНЫ

- сильная зависимость от marker
- OCR кейсы
- таблицы с нестандартной структурой



СИЛЬНЫЕ СТОРОНЫ

- автономность
- решение устойчиво при пакетной обработке
- код короткий, читаемый и легко расширяемый



ВОЗМОЖНЫЕ УЛУЧШЕНИЯ

ОТДЕЛЬНЫЙ ОСР-МОДУЛЬ



ПОСТОБРАБОТКА ТАБЛИЦ



ДЕТЕКТОР МУСОРНЫХ ЭЛЕМЕНТОВ



СИСТЕМА ВАЛИДАЦИИ





СПАСИБО

за внимание

ПРОДАМ ГАРАЖ

